



Klasyfikacja meczów League of Legends przy ograniczonych danych z pierwszych 10 minut meczu

Michał Wojda* (227753), Sebastian Śmietański* (227914),
Tomasz Teofilak* (227674), Tomasz Żołądek* (230998)

*Wydział Zastosowań Informatyki i Matematyki, Szkoła Główna Gospodarstwa Wiejskiego, Warszawa, Polska

(s227753@sggw.edu.pl, s227914@sggw.edu.pl, s227674@sggw.edu.pl, s230998@sggw.edu.pl)

Otrzymano: 09.06.2026 Zaakceptowano: 09.06.2027

Streszczenie- Lorem ipsum dolor sit amet, consectetur adipiscing elit. Cras ex odio, elementum sit amet quam ac, accumsan pharetra libero. Suspendisse odio nisi, consequat sed ornare sed, convallis sed nulla. Nunc nec enim ut nisi facilisis cursus. Cras nec enim neque. Quisque nec consectetur odio. Pellentesque eget euismod sapien. Cras urna urna, gravida a eros eget, tincidunt scelerisque metus. Ut eget mi vehicula augue bibendum dapibus. Ut tempus tellus eros, eu lobortis est dignissim sit amet. Integer id molestie dolor. Mauris tincidunt nunc erat, ut suscipit lacus pharetra varius. Sed quis neque ut ligula vestibulum egestas a sed felis. Quisque vulputate tincidunt metus.

Słowa kluczowe: League of Legends, LoL, klasyfikacja, predykcja wyniku meczu, NAZWY UŻYTYCH METOD

Spis treści

1 Wprowadzenie	3
1.1 Wyjaśnienie terminów	3
2 Przedmiot badania	4
2.1 Cel i zakres badania	4
2.2 Źródło danych	4
2.3 Przegląd literatury	5
3 Wstępna analiza danych	6
3.1 Statystyki opisowe	6
3.2 Braki danych	7
3.3 Wartości odstające	7
3.4 Standaryzowanie danych	7
3.5 Usuwanie cech	8
3.5.1 Quasi Stałe	8
3.5.2 Skorelowane prosto, liniowo	8
3.5.3 Skorelowane wielokrotnie, liniowo	11
3.6 Łączenie zmiennych	12



3.6.1	Agregacja	13
3.6.2	PCA	13
4	Analiza końcowego zbioru danych	17
4.1	Opisy zmiennych	17
4.2	Wizualizacja	17
5	Opisy metod wraz ze wzorami	17
5.1	Opis metody 1	17
5.2	Opis metody 2	17
5.3	Opis metody 3	17
5.4	Opis metody hybrydowej	17
5.5	Opis oceny metody oceniania	17
6	Rezultaty	17
6.1	Rezultat metody 1	17
6.2	Rezultat metody 2	17
6.3	Rezultat metody 3	17
6.4	Rezultat metody hybrydowej	17
6.5	Porównanie skuteczności metod	17
6.6	Użycie najlepszego modelu na syntetycznych danych	17
7	Podsumowanie	17
8	Załączniki	17



1. Wprowadzenie

musi być przynajmniej jedna cytacja żeby latex się nie wywalił [1]

League of Legends jest jedną z najpopularniejszych gier komputerowych typu MOBA (Multiplayer Online Battle Arena), w której dwie pięcioosobowe drużyny rywalizują ze sobą w celu zniszczenia głównej struktury przeciwnika, zwanej Nexusem. Rozgrywka opiera się na współpracy zespołowej, zdobywaniu zasobów oraz stopniowym budowaniu przewagi ekonomicznej i strategicznej nad drużyną przeciwną.

Na przebieg meczu wpływa wiele wzajemnie powiązanych czynników, takich jak liczba eliminacji, zdobywane złoto, doświadczenie bohaterów, kontrola mapy czy przejmowanie neutralnych obiektów. Szczególnie istotna jest początkowa faza rozgrywki, ponieważ to właśnie w pierwszych minutach meczu budowane są podstawy dalszej przewagi, które często mają wpływ na końcowy rezultat spotkania.

Współczesne gry sieciowe generują duże ilości danych opisujących przebieg rozgrywek, co umożliwia wykorzystanie metod analizy danych oraz uczenia maszynowego do badania zależności występujących podczas meczu. Analiza statystyk z wczesnego etapu gry może dostarczyć informacji o typowych schematach prowadzących do zwycięstwa lub porażki drużyny.

Problem badawczy poruszany w niniejszej pracy dotyczy możliwości przewidywania wyniku meczu rankingowego na podstawie statystyk z pierwszych 10 minut rozgrywki. W pracy wykorzystano dane dotyczące meczów rankingowych w celu zbadania, czy metody klasyfikacji pozwalają przewidywać zwycięstwo lub porażkę drużyny niebieskiej na podstawie cech opisujących początkową fazę meczu. Dodatkowym celem jest określenie, które zmienne mają największy wpływ na skuteczność modeli klasyfikacyjnych.

1.1. Wyjaśnienie terminów

- **Doświadczenie** - Doświadczenie (experience, XP) jest zasobem zdobywanym przez bohaterów podczas rozgrywki głównie poprzez przebywanie w pobliżu eliminowanych przeciwników, takich jak miniony czy potwory z dżungli. Zdobycie doświadczenia pozwala bohaterom awansować na kolejne poziomy, co zwiększa ich statystyki oraz umożliwia rozwijanie umiejętności.
- **Złoto** - Złoto jest podstawową walutą występującą w grze. Może być zdobywane między innymi poprzez eliminowanie minionów, bohaterów przeciwnika, potworów z dżungli oraz niszczenie struktur. Zgromadzone złoto pozwala na zakup przedmiotów zwiększających siłę bohatera.
- **Śmierci, zabójstwa i asysty** - Zabójstwo oznacza wyeliminowanie bohatera drużyny przeciwniej. Drużyna zdobywa wówczas złoto oraz przewagę czasową wynikającą z chwilowej nieobecności przeciwnika na mapie. Śmierć oznacza utratę bohatera na określony czas, co ogranicza możliwości drużyny. Asysta przyznawana jest graczom, którzy uczestniczyli w eliminacji przeciwnika, lecz nie zadali decydującego ciosu.
- **First Blood** - First Blood oznacza pierwsze zabójstwo wykonane w meczu. Zdarzenie to zapewnia dodatkową nagrodę w postaci złota i często umożliwia zdobycie wczesnej przewagi nad przeciwnikiem.
- **Wardy** - Wardy są przedmiotami lub umiejętnościami zapewniającymi wizję wybranego obszaru mapy. Mogą być rozmieszczane przez graczy w celu kontrolowania ruchów przeciwnika oraz zabezpieczania ważnych obiektów. Wrogie wardy mogą zostać wykryte i zniszczone przez drużynę przeciwną, co ogranicza dostęp przeciwników do informacji o mapie.
- **Miniony** - Miniony są jednostkami sterowanymi przez komputer, które regularnie pojawiają się w bazach obu drużyn i poruszają się wyznaczonymi liniami mapy. Eliminowanie minionów stanowi jedno z głównych źródeł złota i doświadczenia podczas wczesnej fazy gry.
- **Miniony z dżungli** - Miniony z dżungli, nazywane również potworami neutralnymi, występują w obszarze dżungli pomiędzy liniami. Ich eliminowanie zapewnia złoto, doświadczenie oraz dodatkowe efekty wzmacniające bohaterów.
- **Smoki** - Smoki są neutralnymi potworami pojawiającymi się okresowo na mapie. Ich pokonanie zapewnia drużynie trwałą premie wzmacniającą statystyki bohaterów. Kontrola smoków jest jednym z ważniejszych elementów strategicznych rozgrywki.



- **Heroldy** - Heroldy, określane również jako Rift Herald, są neutralnymi potworami pojawiającymi się we wczesnej i środkowej fazie gry. Po pokonaniu herolda drużyna może przyzwać go na wybranej linii, gdzie pomaga on w niszczeniu struktur przeciwnika.

2. Przedmiot badania

Przedmiotem badania są mecze rankingowe gry League of Legends analizowane na podstawie statystyk pochodzących z pierwszych 10 minut rozgrywki. W pracy skupiono się na zależności pomiędzy wczesną przewagą jednej z drużyn a końcowym wynikiem meczu. Analiza obejmuje zastosowanie metod klasyfikacji w celu sprawdzenia, czy dane dostępne na początkowym etapie gry pozwalają skutecznie przewidywać zwycięstwo lub porażkę drużyny niebieskiej.

2.1. Cel i zakres badania

Celem badania jest klasyfikacja meczów League of Legends na podstawie danych z pierwszych 10 minut rozgrywki przy użyciu kilku metod klasyfikacji, a następnie ocena skuteczności tych metod w przewidywaniu rzeczywistego wyniku meczu, rozumianego jako wygrana lub przegrana drużyny niebieskiej.

Istotnym elementem pracy jest porównanie wyników uzyskanych za pomocą trzech metod klasyfikacji: [NAZWA METODY 1], [NAZWA METODY 2] oraz [NAZWA METODY 3], a także metody mieszanej [NAZWA METODY MIESZANEJ], łączącej cechy wybranych podejść. Celem analizy jest wskazanie, które z zastosowanych rozwiązań najlepiej przewiduje wynik meczu na podstawie danych dostępnych na wczesnym etapie gry.

Analiza ma charakter predykcyjny i koncentruje się na sprawdzeniu, czy informacje dostępne w początkowej fazie meczu pozwalają na skuteczne przewidywanie jego końcowego rezultatu.

Zakres badania obejmuje:

- charakterystykę oraz analizę zbioru danych zawierającego statystyki meczów League of Legends,
- przeprowadzenie wstępnej analizy danych, obejmującej statystyki opisowe oraz analizę korelacji pomiędzy zmiennymi,
- przygotowanie danych do procesu uczenia modeli, w tym obsługę wartości odstających, analizę braków danych, skalowanie cech oraz usunięcie zbędnych zmiennych,
- analizę końcowego zbioru danych po przeprowadzeniu preprocessingu,
- przedstawienie teoretycznych podstaw zastosowanych metod klasyfikacji,
- implementację oraz zastosowanie metod klasyfikacji: [NAZWA METODY 1], [NAZWA METODY 2], [NAZWA METODY 3] oraz [NAZWA METODY HYBRYDOWEJ],
- ocenę skuteczności modeli przy użyciu wybranych miar jakości klasyfikacji,
- analizę i interpretację uzyskanych wyników,
- porównanie skuteczności zastosowanych metod klasyfikacji,
- wykorzystanie najlepszego modelu do klasyfikacji syntetycznie wygenerowanych danych testowych.

Analizę danych oraz implementację modeli klasyfikacyjnych wykonano przy użyciu języka R. Obliczenia przeprowadzono w środowisku RStudio. Użyte biblioteki: [LISTA WSZYSTKICH BIBLIOTEK]

2.2. Źródło danych

W pracy wykorzystano publicznie dostępny zbiór danych zawierający statystyki meczów rankingowych gry League of Legends. Dane pochodzą z serwisu Kaggle i zostały pozyskane przy użyciu oficjalnego API udostępnianego przez Riot Games.



Zbiór obejmuje mecze rankingowe rozgrywane na wysokim poziomie rankingowym tj. od rangi Diamond wzwyż, co odpowiada około 5% najlepszych graczy. Dane pochodzą z okresu sprzed około sześciu lat. Autor zbioru nie określa dokładnego regionu serwerowego, z którego zostały pobrane mecze.

Pojedynczy rekord reprezentuje statystyki obu drużyn po upływie pierwszych 10 minut pojedynczego meczu. Dane opisują sytuację ekonomiczną drużyn, przebieg walk, kontrolę mapy oraz realizację celów neutralnych we wczesnej fazie rozgrywki.

Zbiór danych składa się z 9879 rekordów oraz 40 zmiennych. Zmienną decyzyjną jest blueWins, określająca końcowy wynik meczu z perspektywy drużyny niebieskiej. Wartość zmiennej informuje, czy drużyna niebieska odniosła zwycięstwo.

Klasy w zbiorze danych są w przybliżeniu zbalansowane, co oznacza, że liczba zwycięstw drużyny niebieskiej i czerwonej jest podobna.

2.3. Przegląd literatury

Ze względu na ograniczoną liczbę prac dotyczących wczesnej fazy gry w League of Legends, przegląd oparto głównie na dwóch analizach z Kaggle wykorzystujących ten sam zbiór danych.

Pierwsza praca pokazuje, że już w pierwszych 10 minutach meczu pojawiają się istotne różnice statystyczne między drużynami, które mogą wpływać na dalszy przebieg rozgrywki. Wyniki sugerują, że wczesna faza gry dostarcza informacji o potencjalnym wyniku meczu.

Druga analiza wskazuje, że takie zmienne jak liczba zabójstw, asyst, złoto, doświadczenie i zabite stwory dobrze różnicują mecze wygrane i przegrane. Potwierdza to, że przewaga budowana na początku gry często przekłada się na końcowy rezultat.

Trzecia praca zawiera dokładną analizę wszystkich zmiennych oraz ich wpływu na wynik meczu.

Wnioski przedstawione w analizowanych pracach uzasadniają zastosowane w niniejszej pracy podejście badawcze. Dotychczasowe analizy wskazują, że dane z początkowej fazy rozgrywki zawierają istotną informację predykcyjną, a wykorzystanie metod klasyfikacji może umożliwić skuteczne przewidywanie wyniku meczu na podstawie ograniczonego zestawu cech opisujących pierwsze minuty gry.



3. Wstępna analiza danych

3.1. Statystyki opisowe

Zmienna	Średnia	Mediana	Min.	Maks.	Odch. std.	Skośność
blueWardsPlaced	22.29	16.0	5.0	250.0	18.02	4.14
blueWardsDestroyed	2.82	3.0	0.0	27.0	2.17	2.85
blueFirstBlood	0.50	1.0	0.0	1.0	0.50	-0.02
blueKills	6.18	6.0	0.0	22.0	3.01	0.54
blueDeaths	6.14	6.0	0.0	22.0	2.93	0.51
blueAssists	6.65	6.0	0.0	29.0	4.06	0.89
blueEliteMonsters	0.55	0.0	0.0	2.0	0.63	0.69
blueDragons	0.36	0.0	0.0	1.0	0.48	0.57
blueHeralds	0.19	0.0	0.0	1.0	0.39	1.60
blueTowersDestroyed	0.05	0.0	0.0	4.0	0.24	5.59
blueTotalGold	16503.46	16398.0	10730.0	23701.0	1535.45	0.47
blueAvgLevel	6.92	7.0	4.6	8.0	0.31	-0.34
blueTotalExperience	17928.11	17951.0	10098.0	22224.0	1200.52	-0.25
blueTotalMinionsKilled	216.70	218.0	90.0	283.0	21.86	-0.27
blueTotalJungleMinionsKilled	50.51	50.0	0.0	92.0	9.90	0.12
blueGoldDiff	14.41	14.0	-10830.0	11467.0	2453.35	0.03
blueExperienceDiff	-33.62	-28.0	-9333.0	8348.0	1920.37	0.02
blueCSPerMin	21.67	21.8	9.0	28.3	2.19	-0.27
blueGoldPerMin	1650.35	1639.8	1073.0	2370.1	153.54	0.47
redWardsPlaced	22.37	16.0	6.0	276.0	18.46	4.56
redWardsDestroyed	2.72	2.0	0.0	24.0	2.14	2.95
redFirstBlood	0.50	0.0	0.0	1.0	0.50	0.02
redKills	6.14	6.0	0.0	22.0	2.93	0.51
redDeaths	6.18	6.0	0.0	22.0	3.01	0.54
redAssists	6.66	6.0	0.0	28.0	4.06	0.82
redEliteMonsters	0.57	0.0	0.0	2.0	0.63	0.62
redDragons	0.41	0.0	0.0	1.0	0.49	0.35
redHeralds	0.16	0.0	0.0	1.0	0.37	1.85
redTowersDestroyed	0.04	0.0	0.0	2.0	0.22	5.34
redTotalGold	16489.04	16378.0	11212.0	22732.0	1490.89	0.41
redAvgLevel	6.93	7.0	4.8	8.2	0.31	-0.40
redTotalExperience	17961.73	17974.0	10465.0	22269.0	1198.58	-0.28
redTotalMinionsKilled	217.35	218.0	107.0	289.0	21.91	-0.29
redTotalJungleMinionsKilled	51.31	51.0	4.0	92.0	10.03	0.23
redGoldDiff	-14.41	-14.0	-11467.0	10830.0	2453.35	-0.03
redExperienceDiff	33.62	28.0	-8348.0	9333.0	1920.37	-0.02
redCSPerMin	21.73	21.8	10.7	28.9	2.19	-0.29
redGoldPerMin	1648.90	1637.8	1121.2	2273.2	149.09	0.41

Table 1. Statystyki opisowe wszystkich zmiennych.



3.2. Braki danych

W analizowanym zbiorze danych nie stwierdzono braków danych.

3.3. Wartości odstające

W celu ograniczenia wpływu wartości odstających na działanie modeli klasyfikacyjnych przeprowadzono proces oczyszczania danych. Za wartości odstające uznano jedynie 1% najwyższych wartości zmiennych:

- blueWardsPlaced
- redWardsPlaced

jako że te zmienne miały największą ilość skrajnie dużych wartości. Dodatkowo, takie wartości świadczą o braku poważnego traktowania gry ze strony drużyny charakteryzującej się wysoką wartością zmiennej *WardsPlaced*.

Dlatego dla każdej wyżej wymienionej cechy wyznaczano górny próg odpowiadający wybranemu percentylowi:

$$Q_g = Q_{1-\frac{p}{100}}$$

gdzie:

- Q_g — górny próg dla danej cechy,
- Q — funkcja percentylowa,
- p — procent najwyższych wartości uznawanych za odstające.

Następnie wszystkie wartości większe od wyznaczonego progu były oznaczane jako brakujące:

$$x = \begin{cases} x, & \text{gdy } x \leq Q_g \\ NA, & \text{gdy } x > Q_g \end{cases}$$

Po oznaczeniu wartości odstających jako brakujące usuwano wszystkie rekordy zawierające przynajmniej jedną wartość NA. Ostatecznie ze zbioru danych usunięto 190 rekordów, co stanowiło w przybliżeniu 1.92% wszystkich obserwacji.

Zastosowana metoda pozwoliła ograniczyć wpływ skrajnych obserwacji na proces uczenia modeli oraz zmniejszyć ryzyko zaburzenia działania algorytmów przez nietypowe wartości.

3.4. Standaryzowanie danych

W celu ujednolicenia rozkładów oraz zakresów wartości poszczególnych cech zastosowano standaryzację danych z wykorzystaniem funkcji `scale()` dostępnej w języku R. Metoda ta polega na przekształceniu wartości zmiennych w taki sposób, aby każda cecha posiadała średnią równą 0 oraz odchylenie standardowe równe 1.

Standaryzacja została wykonana zgodnie ze wzorem:

$$x' = \frac{x - \mu}{\sigma}$$

gdzie:

- x — wartość przed skalowaniem,
- μ — średnia wartość danej cechy,



- σ — odchylenie standardowe danej cechy,
- x' — wartość po standaryzacji.

W wyniku zastosowania standaryzacji wszystkie analizowane cechy numeryczne zostały sprowadzone do wspólnej skali. Pozwoliło to ograniczyć wpływ różnic pomiędzy zakresami wartości poszczególnych zmiennych na działanie modeli klasyfikacyjnych oraz poprawić stabilność procesu uczenia.

3.5. Usuwanie cech

Ta podsekcja będzie poświęcona procesowi doboru cech poprzez usuwanie Quasi stałych oraz usuwanie lub łączenie względnie silnie skorelowanych.

3.5.1. Quasi Stałe

Do detekcji Quasi stałych zmiennych wykorzystaliśmy funkcję z pakietu *Caret* o nazwie *nearZeroVar*. Sprawdza ona, czy istnieją jakieś zmienne, które przyjmują tylko jedną unikalną wartość lub mają bardzo mało unikalnych wartości relatywnie i stosunek częstotliwości najczęściej występującej wartości do częstotliwości drugiej najczęściej występującej wartości jest duży, na co wskazuje sama nazwa funkcji. Po jej wykonaniu otrzymaliśmy następującą listę cech:

- blueTowersDestroyed
- redTowersDestroyed

Otrzymaliśmy więc cechę "TowersDestroyed" dla obu drużyn. Dodatkowo z tabeli 1 wiemy, że ich mediany wynoszą 0. Nie powinno to zaskakiwać, jako że w pierwszych 10 minutach rozgrywki - względnie początkowej fazie - rzadko się zdarza zniszczenie wieży przeciwnika. W związku z powyższym usuwamy te 2 cechy z naszego data setu

3.5.2. Skorelowane prosto, liniowo

Cechy skorelowane prosto, liniowo, to takie, pomiędzy którymi istnieje korelacja cecha do cechy. Ergo w tej podsekcji zajmiemy się znajdowaniem takich par i usuwaniu jednej z cech na tej podstawie. Wykorzystamy do tego wbudowaną funkcję w R o nazwie "cor". Za jej pomocą stworzymy macierz korelacji. Wizualizacji dokonamy z wykorzystaniem funkcji "corrplot" z pakietu o tej samej nazwie.




Fig. 1. Macierz korelacji dla wszystkich zmiennych bez quasi stałych 1.



Powyższa macierz przedstawia korelacje liniowe, proste pomiędzy wszystkimi zmiennymi, jakie nam zostały po usunięciu quasi stałych. Na jego podstawie możemy znaleźć bardzo silnie skorelowane, czyli takie, których poziom korelacji jest większy bądź równy 0.9, pary cech:

Cecha A	Cecha B	Korelacja A i B
blueFirstBlood	redFirstBlood	-1
redDeaths	blueKills	1
blueDeaths	redKills	1
blueTotalGold	blueGoldPerMin	1
blueAvgLevel	blueTotalExperience	0.901297
blueTotalMinionsKilled	blueCSPerMin	1
blueGoldDiff	redGoldDiff	-1
blueExperienceDiff	redExperienceDiff	-1
redTotalGold	redGoldPerMin	1
redAvgLevel	redTotalExperience	0.901748
redTotalMinionsKilled	redCSPerMin	1

Table 2. Tabela korelacji silnie skorelowanych zmiennych 1.



Na podstawie powyższego możemy usunąć następujące cechy;

- blueFirstBlood
- redDeaths
- blueDeaths
- blueTotalGold
- blueAvgLevel
- blueTotalMinionsKilled
- blueGoldDiff
- blueExperienceDiff
- redTotalGold
- redAvgLevel
- redTotalMinionsKilled

3.5.3. Skorelowane wielokrotnie, liniowo

Dodatkowo, możemy, korzystając z definicji poszczególnych cech, zebrać korelacje wielokrotne, liniowe; innymi słowy takie korelacje, w których to jedna zmienna jest skorelowana liniowo z więcej niż jedną. Takich relacji mamy aż 6 i są one przedstawione poniżej:

- $blueEliteMonsters = blueDragons + blueHeralds$
- $redEliteMonsters = redDragons + redHeralds$
- $blueGoldDiff = blueTotalGold - redTotalGold$ gdzie blueGoldDiff został już usunięty
- $redGoldDiff = redTotalGold - blueTotalGold$
- $blueExperienceDiff = blueTotalExperience - redTotalExperience$ gdzie blueExperienceDiff został już usunięty
- $redExperienceDiff = redTotalExperience - blueTotalExperience$

Na podstawie wyżej wymienionych relacji usuwamy następujące zmienne:

- $blueEliteMonsters$ i $redEliteMonsters$ jako że istnieje potencjalnie istotna różnica pomiędzy zabiciem heralda a smoka i dlatego wolimy zostawić zmienne z wymienionymi skorelowane
- $blueGoldPerMin$ i $redGoldPerMin$ jako że są one liniowo skorelowane odpowiednio z $blueTotalGold$ i $redTotalGold$ oraz przez wzgląd na to, że uznajemy różnicę między nimi za istotniejszą od tych zmiennych samych w sobie
- $blueTotalExperience$ i $redTotalExperience$ jako że uznajemy różnicę między nimi za istotniejszą od tych zmiennych samych w sobie



3.6. Łączenie zmiennych

Po poprzedniej podsekcji zostały nam cechy przedstawione na narysowanej poniżej macierzy korelacji:




Fig. 2. Macierz korelacji dla wszystkich zmiennych po usuwaniu liniowo skorelowanych



3.6.1. Agregacja

Jak można wyczytać z powyższej macierzy, mamy 3 pary silnie skorelowanych cech. Spośród nich 2 to następujące pary:

Cecha A	Cecha B	Korelacja A i B
redKills	redAssists	0.8
blueKills	blueAssists	0.81

Table 3. Tabela korelacji silnie skorelowanych zmiennych 2.

Te cechy zagrągujemy liniowo w jedną, dla każdej drużyny, wedle następującej reguły:

$$KA = Kills + Assists$$

Tym samym otrzymujemy następujące nowe cechy:

- blueKA
- redKA

3.6.2. PCA

Po agregacji została nam następująca para cech silnie skorelowanych:

$$\text{redGoldDiff} \quad \text{redExperienceDiff} \quad 0.89$$

Do zagregowania tych zmiennych wykorzystamy metodę PCA. Poniżej przedstawimy, opis tej metody:

Niech macierz danych będzie opisana jako

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

gdzie n oznacza liczbę obserwacji, a p liczbę zmiennych. Metoda PCA przekształca pierwotny zbiór p skorelowanych zmiennych w nowy zbiór zmiennych, zwanych **głównymi składowymi**, które są wzajemnie nieskorelowane i uporządkowane według malejącej wariancji.

W pierwszym kroku dane są zwykle centrowane, a w przypadku zmiennych mierzonych w różnych skalach również standaryzowane. Następnie wyznacza się macierz kowariancji:

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}^\top \mathbf{X},$$

lub, w przypadku danych standaryzowanych, macierz korelacji.

Kolejnym etapem jest wyznaczenie wartości własnych i wektorów własnych macierzy $\mathbf{S}$:

$$\mathbf{S} \mathbf{v}_k = \lambda_k \mathbf{v}_k,$$

gdzie λ_k oznacza k -tą wartość własną, a $\mathbf{v}_k$ odpowiadający jej wektor własny. Wektory własne wyznaczają kierunki głównych składowych, natomiast wartości własne informują o ilości wariancji wyjaśnianej przez każdą składową.



Główne składowe wyznacza się jako liniowe kombinacje zmiennych pierwotnych:

$$\mathbf{z}_k = \mathbf{X}\mathbf{v}_k.$$

Pierwsza główna składowa wyjaśnia największą możliwą część wariancji danych, druga – największą część pozostałej wariancji, przy zachowaniu ortogonalności względem pierwszej, itd.

Redukcja wymiarowości polega na wyborze pierwszych m składowych, gdzie $m < p$, tak aby zachować jak największą część całkowitej zmienności danych. Udział wariancji wyjaśnionej przez k -tą składową można obliczyć jako:

$$\frac{\lambda_k}{\sum_{j=1}^p \lambda_j}.$$

Z kolei skumulowany udział wyjaśnionej wariancji dla pierwszych m składowych wynosi:

$$\frac{\sum_{k=1}^m \lambda_k}{\sum_{j=1}^p \lambda_j}.$$

W praktyce wybiera się taką liczbę składowych, aby skumulowana wariancja osiągała założony poziom, np. 80%, 90% lub 95%. Dzięki temu możliwe jest zastąpienie dużej liczby zmiennych mniejszym zbiorem nowych cech, co upraszcza analizę, zmniejsza złożoność modeli oraz ogranicza problem współliniowości.

W skrypcie będziemy bazować na wbudowanej funkcji "prcomp" i do wizualizacji rzutu wykorzystamy funkcję "fviz_pca_biplot" z biblioteki factoextra. Poniżej przedstawiony jest wykres po zastosowaniu PCA.




Fig. 3. Wykres PCA dla cech redGoldDiff i redExperienceDiff

Jak na załączonym wyżej obrazku widać, nowa cecha, roboczo nazwana *Dim1*, odpowiada za aż około 94.7% wariancji. Stąd też możemy uznać, że taka agregacja będzie dobrą formą wyeliminowania silnej korelacji. Od tego momentu zmienna robocza nazwana *Dim1* będzie miała nazwę *diff_PCA_Component_1*.

Po wykonaniu wszystkich kroków usuwania silnie i bardzo silnie skorelowanych cech możemy przedstawić jak ostatecznie wygląda macierz korelacji. Dodatkowo macierz uwzględnia cechę *blueWins*, aby dodatkowo ukazać jak silnie jest ona skorelowana ze zmiennymi, które ostatecznie zostały.




Fig. 4. Macierz korelacji dla wszystkich zmiennych po usuwaniu liniowo skorelowanych



4. Analiza końcowego zbioru danych

4.1. Opisy zmiennych

4.2. Wizualizacja

5. Opisy metod wraz ze wzorami

5.1. Opis metody 1

5.2. Opis metody 2

5.3. Opis metody 3

5.4. Opis metody hybrydowej

5.5. Opis oceny metody oceniania

6. Rezultaty

6.1. Rezultat metody 1

6.2. Rezultat metody 2

6.3. Rezultat metody 3

6.4. Rezultat metody hybrydowej

6.5. Porównanie skuteczności metod

6.6. Użycie najlepszego modelu na syntetycznych danych

7. Podsumowanie

8. Załączniki

Literatura

- [1] International Energy Agency, “World energy outlook 2023.” <https://www.iea.org/reports/world-energy-outlook-2023>, 2023. Last accessed: March 2026.